

Trabalho II do Algoritmo k-NN para Reconhecimento de Dígitos (0-9)

Carolina Yumi Fujii

RA: 2335468

¹Universidade Tecnológica Federal do Paraná

Campus Campo Mourão

Departamento de Computação - DACOM

Prof. Dr. Juliano Henrique Foleiss

(julianofoleiss@utfpr.edu.br)

Disciplina: BCC35-G - Inteligência Artificial

Abstract. This paper presents an analysis of the k-NN algorithm performance for digit recognition (0-9), using different distance metrics (Euclidean and Manhattan) and normalization methods (Min-Max and Z-score). Accuracy was evaluated for various k values and different training set splits (25%, 50%, and 100%).

Resumo. Este artigo apresenta uma análise do desempenho do algoritmo k-NN para o reconhecimento de dígitos de 0 a 9, utilizando diferentes métricas de distância (Euclíadiana e Manhattan) e métodos de normalização (Min-Max e Z-score). Foram avaliadas a acurácia para diferentes valores de k e diferentes divisões do conjunto de treinamento (25%, 50% e 100%).

1. Introdução

O algoritmo k-NN é amplamente utilizado em problemas de classificação e reconhecimento de padrões devido à sua simplicidade e eficácia. Neste estudo, investigamos o desempenho do k-NN para reconhecimento de dígitos, analisando a influência da escolha da métrica de distância e do método de normalização nos resultados obtidos.

2. Metodologia

O conjunto de dados utilizado para este estudo contém imagens de dígitos de 0 a 9. O algoritmo k-NN foi implementado em Python, e os seguintes aspectos foram considerados:

- Métricas de Distância: Distância Euclidiana e Manhattan.
- Métodos de Normalização: Min-Max e Z-score.
- Divisão do Conjunto de Treinamento: 25%, 50% e 100%.

Foram avaliadas as acuráncias para diferentes valores de k (1, 3, 5, 7, 9, 11, 13, 15, 17, 19) para cada combinação de métrica de distância, método de normalização e divisão do conjunto de treinamento.

3. Resultados

3.1. Features Disponíveis

k=1	Acurácia: 89.60%	k=1	Acurácia: 89.40%
k=3	Acurácia: 90.80%	k=3	Acurácia: 88.80%
k=5	Acurácia: 90.90%	k=5	Acurácia: 89.60%
k=7	Acurácia: 91.00%	k=7	Acurácia: 89.50%
k=9	Acurácia: 90.60%	k=9	Acurácia: 90.10%
k=11	Acurácia: 90.40%	k=11	Acurácia: 90.70%
k=13	Acurácia: 89.40%	k=13	Acurácia: 90.70%
k=15	Acurácia: 88.90%	k=15	Acurácia: 90.50%
k=17	Acurácia: 88.30%	k=17	Acurácia: 90.00%
k=19	Acurácia: 87.50%	k=19	Acurácia: 89.60%

Tabela 1: Divisão do conjunto de treinamento: 25% Distância Euclidiana e Distância Manhattan

k=1	Acurácia: 91.60%	k=1	Acurácia: 93.70%
k=3	Acurácia: 93.30%	k=3	Acurácia: 94.20%
k=5	Acurácia: 93.90%	k=5	Acurácia: 94.00%
k=7	Acurácia: 93.70%	k=7	Acurácia: 93.00%
k=9	Acurácia: 93.50%	k=9	Acurácia: 93.40%
k=11	Acurácia: 92.30%	k=11	Acurácia: 93.90%
k=13	Acurácia: 92.00%	k=13	Acurácia: 93.80%
k=15	Acurácia: 92.30%	k=15	Acurácia: 93.50%
k=17	Acurácia: 91.90%	k=17	Acurácia: 92.70%
k=19	Acurácia: 91.70%	k=19	Acurácia: 92.40%

Tabela 2: Divisão do conjunto de treinamento: 50% Distância Euclidiana e Distância Manhattan

k=1	Acurácia: 92.70%	k=1	Acurácia: 93.50%
-----	------------------	-----	------------------

k=3	Acurácia: 93.10%	k=3	Acurácia: 94.60%
k=5	Acurácia: 94.80%	k=5	Acurácia: 95.20%
k=7	Acurácia: 94.80%	k=7	Acurácia: 95.00%
k=9	Acurácia: 94.90%	k=9	Acurácia: 95.20%
k=11	Acurácia: 94.70%	k=11	Acurácia: 94.60%
k=13	Acurácia: 94.40%	k=13	Acurácia: 94.40%
k=15	Acurácia: 94.20%	k=15	Acurácia: 94.70%
k=17	Acurácia: 93.90%	k=17	Acurácia: 94.70%
k=19	Acurácia: 93.70%	k=19	Acurácia: 94.60%

Tabela 3: Divisão do conjunto de treinamento: 100% Distância Euclidiana e Distância Manhattan

3.2. Features Extraídos

k=1	Acurácia: 88.50%	k=1	Acurácia: 90.70%
k=3	Acurácia: 89.40%	k=3	Acurácia: 91.80%
k=5	Acurácia: 90.20%	k=5	Acurácia: 92.80%
k=7	Acurácia: 88.50%	k=7	Acurácia: 92.00%
k=9	Acurácia: 89.10%	k=9	Acurácia: 90.50%
k=11	Acurácia: 88.70%	k=11	Acurácia: 89.90%
k=13	Acurácia: 88.80%	k=13	Acurácia: 88.90%
k=15	Acurácia: 87.80%	k=15	Acurácia: 89.20%
k=17	Acurácia: 87.30%	k=17	Acurácia: 88.30%
k=19	Acurácia: 85.60%	k=19	Acurácia: 87.00%

Tabela 4: Divisão do conjunto de treinamento com Features Extraídos: 25% Distância Euclidiana e Distância Manhattan

k=1	Acurácia: 89.50%	k=1	Acurácia: 91.70%
k=3	Acurácia: 91.30%	k=3	Acurácia: 93.50%
k=5	Acurácia: 92.40%	k=5	Acurácia: 94.00%
k=7	Acurácia: 91.90%	k=7	Acurácia: 94.10%

k=9	Acurácia: 92.00%	k=9	Acurácia: 94.10%
k=11	Acurácia: 92.10%	k=11	Acurácia: 93.80%
k=13	Acurácia: 91.30%	k=13	Acurácia: 93.50%
k=15	Acurácia: 90.50%	k=15	Acurácia: 93.60%
k=17	Acurácia: 91.10%	k=17	Acurácia: 93.10%
k=19	Acurácia: 91.50%	k=19	Acurácia: 93.00%

**Tabela 5: Divisão do conjunto de treinamento com Features Extraídos: 50%
Distância Euclidiana e Distância Manhattan**

k=1	Acurácia: 91.00%	k=1	Acurácia: 93.10%
k=3	Acurácia: 90.60%	k=3	Acurácia: 93.40%
k=5	Acurácia: 91.70%	k=5	Acurácia: 93.50%
k=7	Acurácia: 92.80%	k=7	Acurácia: 93.70%
k=9	Acurácia: 93.20%	k=9	Acurácia: 93.90%
k=11	Acurácia: 93.20%	k=11	Acurácia: 94.10%
k=13	Acurácia: 93.10%	k=13	Acurácia: 94.80%
k=15	Acurácia: 92.80%	k=15	Acurácia: 95.10%
k=17	Acurácia: 92.70%	k=17	Acurácia: 95.00%
k=19	Acurácia: 92.80%	k=19	Acurácia: 94.90%

**Tabela 5: Divisão do conjunto de treinamento com Features Extraídos: 100%
Distância Euclidiana e Distância Manhattan**

4. Conclusão

O método de normalização e a quantidade de dados de treinamento têm um impacto significativo na acurácia do classificador k-NN. Valores intermediários de k tendem a oferecer um equilíbrio entre viés e variância, enquanto a normalização Z-score e o uso de uma maior proporção dos dados de treinamento geralmente melhoraram o desempenho do modelo. A distância Manhattan mostrou-se ligeiramente mais eficaz do que a distância Euclidiana na maioria dos cenários, especialmente com normalização Z-score e em grandes divisões do conjunto de treinamento.